

# Entendendo Primal, Dual e Sensibilidade no JuMP

## Forma Primal vs. Dual

Em otimização, todo problema (o **Primal**) tem um problema "espelho" associado (o **Dual**).

No JuMP, a regra geral é: **Você sempre escreve o problema Primal.**

### O Problema Primal (O que você escreve)

- É o problema original que você quer resolver.
- **Exemplo:** *Maximizar* o lucro (função objetivo) sujeito a limitações de recursos como madeira, aço e mão de obra (restrições).
- As variáveis são suas decisões: `x` , `y` .
- A solução é `value(x)` e `value(y)` .

## O Problema Dual (O "espelho" calculado)

- É um problema matemático derivado do primal.
- **Exemplo:** Se o primal *maximiza* lucro, o dual *minimiza* o "custo" ou "valor" dos recursos.
- Cada **restrição** no Primal (ex: `c_madeira <= 100`) corresponde a uma **variável dual** no Dual.
- O JuMP permite acessar a *solução* desse problema dual (o valor dessas variáveis duais) sem que você precise escrevê-lo.

# Diferença Prática no Código

```
# 1. DEFININDO O MODELO PRIMAL
model = Model(HiGHS.Optimizer)

@variable(model, x >= 0)
@variable(model, y >= 0)

# 'c_madeira' é uma restrição PRIMAL
@constraint(model, c_madeira, 2x + y <= 100)

@objective(model, Max, 40x + 30y)

optimize!(model)

# 2. ACESSANDO AS SOLUÇÕES

# Solução PRIMAL (Quanto produzir de x e y)
primal_x = value(x)
primal_y = value(y)

# Solução DUAL (O valor da restrição 'c_madeira')
dual_madeira = shadow_price(c_madeira)
```

**Resumo:** Você define o Primal ( `@variable` , `@constraint` ) para obter as soluções primais ( `value()` ). Depois, você pode consultar as soluções duais ( `shadow_price()` ) que foram calculadas pelo solver.



## O que é Análise de Sensibilidade?

A Análise de Sensibilidade estuda como a **solução ótima** (lucro, valores de  $x$ ,  $y$ ) muda quando os **parâmetros** do modelo (limites de recursos, custos, lucros) mudam.

No JuMP, isso é feito principalmente através de duas funções:

### 1. Preço Sombra (Shadow Price)

- **O que é:** Informa o quanto a sua **função objetivo** (ex: lucro) irá melhorar se você **relaxar uma restrição** em uma unidade.
- **Função no JuMP:** `shadow_price(sua_restricao)`

- **Exemplo Prático:**

- Você tem a restrição: `@constraint(model, c_madeira, ... <= 100)`
- Você roda `optimize!(model)` e descobre que:
- `shadow_price(c_madeira)` é \$30.

- **Significado:**

- Isso quer dizer que, se você conseguir +1 unidade de madeira (mudando a restrição para `<= 101`), seu lucro total **aumentará em \$30**.
- Se o preço sombra for 0, significa que essa restrição não está te limitando (você já tem madeira de sobra).

## 2. Custo Reduzido (Reduced Cost)

- **O que é:** Focado nas **variáveis** (ex: produtos). Se uma variável é **zero** na solução ótima (ex: o modelo decidiu "não produzir o Produto Z"), o custo reduzido informa quanto o coeficiente dela na função objetivo (ex: seu lucro) precisa **melhorar** para que valha a pena produzi-la.
- **Função no JuMP:** `reduced_cost(sua_variavel)`
- **Exemplo Prático:**
  - Você tem a variável `@variable(model, z >= 0)` e o objetivo é `Max, ... + 40z`.
  - Você roda `optimize!(model)` e descobre que `value(z)` é 0 (o modelo não quis produzir `z`).
  - Você consulta `reduced_cost(z)` e o valor é -20.

- **Significado:**
  - O lucro do produto  $z$  (que era \$40) precisa aumentar em \$20 (ou seja, ir para \$60) antes que o modelo considere produzir  $z$  (antes que  $\text{value}(z)$  se torne positivo).